☕ Regresión lineal aplicada: ¿cuántos cafés venderemos mañana?

🎯 ¿Qué vamos a aprender?

Ya construimos nuestro primer modelo de regresión lineal utilizando Python. Aprendimos a explorar datos, encontrar patrones, entrenar un modelo y hacer predicciones.

Ahora vamos a utilizar esos conocimientos para resolver un problema de negocio.

Porque la ciencia de datos no se trata solamente de crear modelos, sino también de **utilizar la información para tomar mejores decisiones**.

☕ 1. Tenemos una cafetería

Imagina que tenemos una cafetería y queremos mejorar la forma en que planeamos nuestras ventas.

Todos los días necesitamos decidir cuántos insumos comprar, cuánto personal necesitaremos y cuántos cafés podríamos vender.

Pero hay un pequeño problema: **no sabemos exactamente cuántos clientes llegarán mañana**.

Lo que sí tenemos es información de los últimos 90 días:

- La temperatura promedio de cada día.
- La cantidad de cafés calientes que vendimos.

Y se nos ocurre una pregunta:

¿Será que cuando hace frío vendemos más cafés calientes? 🥶

Si encontramos una relación entre la temperatura y las ventas, podríamos utilizarla para estimar cuántos cafés venderemos en los próximos días.

¡Vamos a investigarlo!

📊 2. Conozcamos nuestras ventas

Primero vamos a cargar nuestro archivo `cafe.csv` y revisar qué información contiene.

```
None
import pandas as pd
import matplotlib.pyplot as plt

datos = pd.read_csv("cafe.csv")

datos.head()
```

	temperatura_c	cafes_vendidos
0	24	78
1	23	94
2	18	114
3	22	114
4	19	132

Nuestro dataset contiene dos columnas:

`temperatura_c`: la temperatura promedio del día, medida en grados Celsius.

`cafes_vendidos`: la cantidad de cafés calientes vendidos durante ese día.

Cada fila representa un día diferente de operación de nuestra cafetería.

Ahora revisemos algunos datos generales:

```
None
datos.describe()
```

	temperatura_c	cafes_vendidos
count	90.000000	90.000000
mean	23.500000	89.522222
std	5.202096	20.182442
min	15.000000	47.000000
25%	19.250000	73.500000
50%	23.000000	90.000000
75%	27.750000	104.000000
max	33.000000	132.000000

🔎 Pensemos como dueños de la cafetería

Observa los resultados y responde:

- ¿Cuántos cafés vendemos en promedio por día?
- ¿Cuál fue nuestra venta más alta?
- ¿Qué temperatura promedio tuvimos durante estos 90 días?

Estos números nos ayudan a conocer el comportamiento general de nuestro negocio.

Pero todavía queremos descubrir si existe una relación entre la temperatura y las ventas.

📉 3. ¿El clima afecta nuestras ventas?

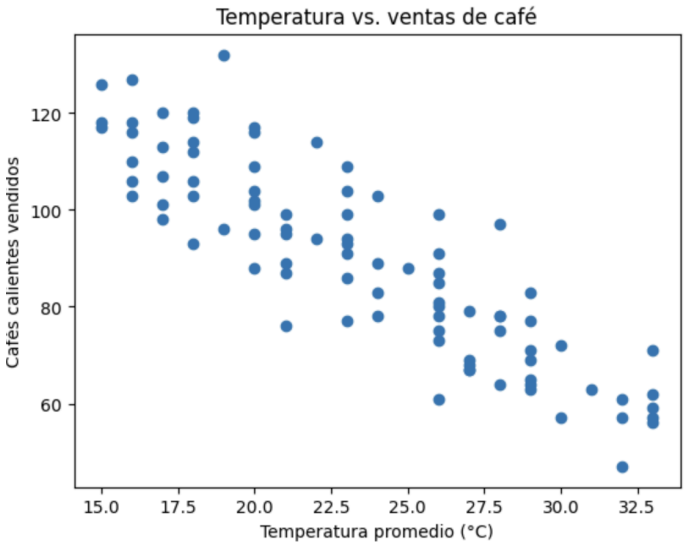
Vamos a utilizar una gráfica de dispersión para visualizar nuestros datos.

None

```
plt.scatter(
    datos["temperatura_c"],
    datos["cafes_vendidos"]
)

plt.xlabel("Temperatura promedio (°C)")
plt.ylabel("Cafés calientes vendidos")
plt.title("Temperatura vs. ventas de café")

plt.show()
```



👀 ¿Qué observamos?

Cada punto representa un día de ventas.

En el eje horizontal tenemos la temperatura y en el vertical la cantidad de cafés vendidos.

Observa cómo se distribuyen los puntos.

¿Qué sucede con las ventas cuando aumenta la temperatura?

En general, parece que los días más calurosos vendemos menos cafés calientes.

¡Tiene sentido! Cuando hace frío, muchas personas prefieren una bebida caliente. ☕

Pero no todos los días se comportan exactamente igual.

Tal vez un día tuvimos una promoción, otro día llovió o simplemente llegaron más clientes de lo habitual.

Nuestro modelo no conocerá todos esos factores, pero sí podrá ayudarnos a encontrar la tendencia general.

🤖 4. Construyamos nuestro modelo

Ahora vamos a utilizar regresión lineal para encontrar la relación entre la temperatura y las ventas.

Ya conocemos el procedimiento, así que ¡manos a Python!

```
None
from sklearn.linear_model import LinearRegression

X = datos[["temperatura_c"]]
y = datos["cafes_vendidos"]

modelo = LinearRegression()
modelo.fit(X, y)
```

¡Listo! Nuestro modelo ya encontró la línea que mejor representa la relación entre la temperatura y las ventas.

Ahora revisemos sus valores:

```
None
print("Pendiente:", modelo.coef_[0])
print("Intercepto:", modelo.intercept_)
```

```
Pendiente: -3.41810255345651
Intercepto: 169.8476322284502
```

💡 ¿Qué significa esto para nuestro negocio?

La **pendiente** nos dice cómo cambian las ventas estimadas cuando la temperatura aumenta un grado.

Por ejemplo, si obtenemos una pendiente cercana a **-3**, significa que por cada grado Celsius adicional, nuestro modelo estima aproximadamente tres cafés calientes menos vendidos.

El **intercepto** representa las ventas que estimaría el modelo a 0 °C.

Pero ¡ojo! Nuestros datos no incluyen temperaturas tan bajas, así que no deberíamos confiar demasiado en esa estimación.

Lo importante es que ahora tenemos una ecuación que relaciona la temperatura con nuestras ventas.

Y podemos utilizarla para planear mejor nuestro negocio.

🔮 5. ¿Cuántos cafés venderemos mañana?

Imaginemos que revisamos el pronóstico del clima y mañana tendremos una temperatura promedio de **20 °C**.

Como ya tenemos nuestro modelo entrenado, podemos preguntarle cuántos cafés calientes estima que venderemos.

🐍 Manos a Python

```
None
manana = pd.DataFrame({
    "temperatura_c": [20]
})

prediccion = modelo.predict(manana)

print("Ventas estimadas:", round(prediccion[0]), "cafés")
```

```
Ventas estimadas: 101 cafés
```

☕ ¿Qué significa este resultado?

Nuestro modelo utilizó la temperatura de 20 °C para estimar cuántos cafés podríamos vender mañana.

¡Ya tenemos una predicción que podemos utilizar para planear nuestro negocio!

Pero recuerda: **es una estimación, no una promesa de ventas**.

📊 6. ¿Qué pasa si cambia el clima?

Ahora imaginemos que queremos planear las ventas para tres días con temperaturas diferentes.

En lugar de hacer una predicción por separado, podemos calcularlas todas al mismo tiempo.

None

```
pronostico = pd.DataFrame({
    "temperatura_c": [16, 24, 32]
})

pronostico["ventas_estimadas"] = modelo.predict(
    pronostico[["temperatura_c"]]
).round().astype(int)

pronostico
```

	temperatura_c	ventas_estimadas
0	16	115
1	24	88
2	32	60

🔎 Analicemos nuestros resultados

Observa la nueva tabla.

¿En cuál de los tres días esperamos vender más cafés calientes?

¿En cuál esperamos vender menos?

Nuestro modelo encontró una relación negativa entre temperatura y ventas: **cuando la temperatura aumenta, las ventas estimadas disminuyen**.

Esto puede ayudarnos a anticipar la demanda en lugar de esperar hasta el final del día para saber cuánto vendimos.

📈 7. Visualicemos nuestras predicciones

Vamos a dibujar la línea de regresión sobre nuestros datos para observar cómo cambian las ventas estimadas según la temperatura.

```
None
import numpy as np

temperaturas = np.linspace(
    datos["temperatura_c"].min(),
    datos["temperatura_c"].max(),
    100
)

nuevas_temperaturas = pd.DataFrame({
    "temperatura_c": temperaturas
})

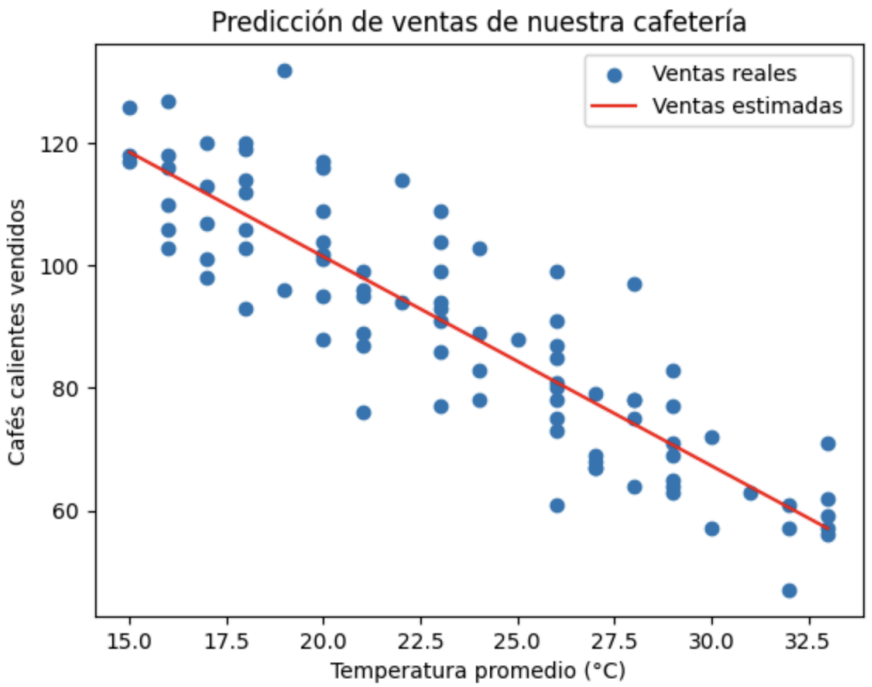
ventas_estimadas = modelo.predict(nuevas_temperaturas)

plt.scatter(
    datos["temperatura_c"],
    datos["cafes_vendidos"],
    label="Ventas reales"
)

plt.plot(
    temperaturas,
    ventas_estimadas,
    color="red",
    label="Ventas estimadas"
)
```

```
plt.xlabel("Temperatura promedio (°C)")
plt.ylabel("Cafés calientes vendidos")
plt.title("Predicción de ventas de nuestra cafetería")

plt.legend()
plt.show()
```



👀 ¿Qué estamos viendo?

Los puntos representan las ventas que realmente registramos durante los 90 días.

La línea roja muestra lo que nuestro modelo estima para cada temperatura.

Como la línea desciende, podemos observar que **el modelo espera menos ventas de café caliente conforme aumenta la temperatura**.

Y aunque algunos puntos están lejos de la línea, esta nos ayuda a identificar la tendencia general.

💰 8. ¡Pensemos como dueños de un negocio!

Hasta ahora hemos utilizado Python para analizar datos y hacer predicciones.

Pero ¿cómo podemos aprovechar esta información?

Imagina que nuestra cafetería necesita decidir cuánta leche, café y vasos comprar para los próximos días.

Si esperamos vender 100 cafés, probablemente necesitaremos más insumos que si esperamos vender solamente 60.

Y aquí aparece algo importante:

Una predicción se vuelve valiosa cuando nos ayuda a tomar una decisión.

Por ejemplo, podríamos utilizar nuestro modelo para:

- ☕ Planear cuántos insumos comprar.
- 📦 Evitar quedarnos sin productos durante los días de mayor demanda.
- 💸 Reducir desperdicios y compras innecesarias.
- 👥 Organizar mejor los turnos del personal.

🤔 Un pequeño reto de negocio

Imagina que mañana nuestro modelo estima que venderemos **85 cafés calientes**.

Supongamos que cada café necesita 200 ml de leche.

¿Cuántos litros de leche necesitaríamos si todos los cafés utilizaran esa cantidad?

None

```
cafes_estimados = 85
leche_por_cafe = 200

litros_leche = (
    cafes_estimados * leche_por_cafe
) / 1000

print("Leche necesaria:", litros_leche, "litros")
```

```
Leche necesaria: 17.0 litros
```

¡Necesitaríamos 17 litros de leche!

Pero ¿comprarías exactamente 17 litros?

Tal vez considerarías un pequeño margen adicional por si llegan más clientes de lo esperado.

Y también tendrías que pensar si todos tus cafés llevan leche, cuánto inventario tienes disponible y cuánto producto podría desperdiciarse.

El modelo nos ayuda a estimar la demanda, pero nosotros seguimos tomando las decisiones.

🎯 9. ¿Qué tan cerca estuvo nuestro modelo?

Vamos a calcular el error absoluto promedio (MAE), igual que hicimos con los corredores.

```
None
from sklearn.metrics import mean_absolute_error

predicciones = modelo.predict(X)

error = mean_absolute_error(y, predicciones)

print("Error promedio:", round(error, 2), "cafés")
```

```
Error promedio: 7.35 cafés
```

🔎 ¿Cómo interpretamos el resultado?

El MAE nos dice cuántos cafés se alejan, en promedio, nuestras predicciones de las ventas registradas.

Por ejemplo, si obtenemos un MAE de 8 cafés, significa que nuestras estimaciones tienen una diferencia promedio de aproximadamente 8 cafés respecto a las ventas reales.

Este error está calculado con los mismos datos que utilizamos para entrenar el modelo. Nos ayuda a conocer su ajuste, pero todavía no nos dice qué tan bien funcionará con días nuevos.

Más adelante aprenderemos a comprobarlo.

💜 10. ¿Qué aprendimos de nuestra cafetería?

Comenzamos con una pregunta sencilla:

¿Podemos utilizar la temperatura para estimar cuántos cafés calientes venderemos?

Y utilizando regresión lineal logramos encontrar un patrón, construir un modelo y utilizarlo para hacer predicciones.

Pero también descubrimos algo importante: **nuestro modelo no conoce todo lo que sucede en el negocio**.

No sabe si mañana habrá una promoción, si es día festivo, si está lloviendo o si hay un evento cerca de la cafetería.

Por eso, aunque nuestras predicciones pueden ser útiles, siempre debemos interpretarlas con cuidado.

🚀 La ciencia de datos va más allá de los números

Crear un modelo es solamente una parte del trabajo.

También necesitamos entender el problema, interpretar los resultados y pensar cómo utilizar la información.

No se trata de que Python tome las decisiones por nosotros, sino de que nos ayude a tomar decisiones mejor informadas.